

تحليل آماری داده‌های تبلیغاتی و بررسی اثر رسانه‌های مختلف بر فروش

تهیه کننده: امیر حسین نجفی

خردادماه ۱۴۰۵



۱. مقدمه	۳
۲. تعریف مسئله و هدف پروژه	۳
۳. معرفی داده‌ها	۴
۴. تحلیل اکتشافی داده‌ها	۴
۴.۱ بررسی اولیه داده‌ها (Initial Data Inspection)	۴
۴.۱.۱ بارگذاری داده و مشاهده چند سطر اول	۴
۴.۱.۲ بررسی ساختار داده‌ها	۵
۴.۱.۳ بررسی داده‌های گمشده	۵
۴.۱.۴ حذف ستون شناسه	۵
۴.۲ آمار توصیفی (Descriptive Statistics)	۵
۴.۲.۱ محاسبه آمار توصیفی	۶
۴.۳ تحلیل بصری با هیستوگرام (Histograms)	۶
۴.۴ شناسایی داده‌های پرت با باکس پلات (Boxplots)	۷
۴.۵ تحلیل همبستگی (Correlation Analysis)	۸
۵. تحلیل ماتریسی و کاهش ابعاد	۹
۵.۱ محاسبه ماتریس کوواریانس هزینه‌های تبلیغات	۹
۵.۲ استخراج مقادیر ویژه و بردارهای ویژه	۹
۵.۳ انجام SVD روی داده‌های استاندارد شده	۱۱
۵.۴ محاسبه نسبت واریانس توضیح داده شده (Explained Variance Ratio)	۱۲
۶. مدل سازی رگرسیون خطی	۱۳
۶.۱ تعریف مدل و آماده سازی ماتریس طراحی	۱۳
۶.۲ محاسبه ضرایب مدل با روش حداقل مربعات و شبه معکوس SVD	۱۴
۶.۲.۱ روش اول: محاسبه ضرایب با استفاده از معادله نرمال	۱۵
۶.۲.۲ روش دوم: محاسبه ضرایب با استفاده از شبه معکوس مبنی بر SVD	۱۵
۶.۲.۳ مقایسه نهایی نتایج دو روش	۱۶

۶.۳	محاسبه خطای استاندارد ضرایب	۱۶
۶.۴	آزمون t برای ضرایب رگرسیون	۱۷
۶.۵	محاسبه p -value ضرایب	۱۸
۷	استدلال بیزی	۱۹
۷.۱	تعریف فروش بالا بر اساس میانه	۱۹
۷.۲	به روزرسانی توزیع Beta	۱۹
۸	جمع بندی نهایی	۲۰

۱. مقدمه

در این پروژه، از یک مجموعه داده واقعی در حوزه تبلیغات استفاده شده است که شامل میزان هزینه تبلیغات در سه رسانه تلویزیون (TV)، رادیو (Radio) و روزنامه (Newspaper) و همچنین میزان فروش (Sales) است. هدف اصلی پروژه، بررسی رابطه بین هزینه‌های تبلیغاتی و میزان فروش با استفاده از ابزارهای آماری، جبر خطی و روش‌های احتمالاتی است.

در این راستا، ابتدا داده‌ها به صورت توصیفی بررسی می‌شوند تا ساختار کلی، توزیع متغیرها و ویژگی‌های آماری آن‌ها مشخص شود. سپس با استفاده از مفاهیمی مانند ماتریس کوواریانس، مقادیر ویژه، بردارهای ویژه و تجزیه مقدار منفرد (SVD)، ساختار پنهان داده‌ها و سهم هر مؤلفه در تغییرات داده تحلیل می‌شود. در ادامه، یک مدل رگرسیون خطی برای پیش‌بینی فروش بر اساس هزینه‌های تبلیغاتی ساخته می‌شود و ضرایب آن با استفاده از روش حداقل مربعات و شبه معکوس مبتنی بر SVD محاسبه می‌گردد. در نهایت، با استفاده از استدلال بیزی، احتمال وقوع فروش بالا برآورد می‌شود.

۲. تعریف مسئله و هدف پروژه

مسئله اصلی این پروژه، تحلیل تأثیر هزینه‌های تبلیغاتی در رسانه‌های مختلف بر میزان فروش است. به بیان دقیق‌تر، می‌خواهیم بررسی کنیم که آیا متغیرهای TV، Radio و Newspaper می‌توانند تغییرات Sales را توضیح دهند و کدام یک از این متغیرها نقش مهم‌تری در پیش‌بینی فروش دارند.

برای پاسخ به این مسئله، پروژه در چند گام انجام می‌شود. ابتدا داده‌ها از نظر آماری و توصیفی بررسی می‌شوند. سپس ساختار همبستگی و پراکندگی داده‌ها با استفاده از تحلیل ماتریسی و کاهش ابعاد مطالعه می‌شود. در ادامه، یک مدل رگرسیون خطی چندمتغیره به صورت $Sales = \beta_0 + \beta_1 TV + \beta_2 Radio + \beta_3 Newspaper$ تشکیل می‌شود تا میزان اثر هر رسانه بر فروش تعیین شود. علاوه بر این، در بخش استدلال بیزی، فروش بالا به عنوان فروش بزرگ‌تر از میان فروش تعریف شده و احتمال وقوع آن با استفاده از توزیع پیشین $Beta(1,1)$ و داده‌های مشاهده شده برآورد می‌شود.

اهداف این پروژه به صورت زیر است:

۱. بررسی آماری و توصیفی داده‌های تبلیغات و فروش
۲. تحلیل توزیع متغیرها با استفاده از نمودارهای مناسب
۳. محاسبه ماتریس کوواریانس و تحلیل ساختار داده‌ها
۴. اجرای تجزیه مقدار منفرد (SVD) روی داده‌های نرمال شده
۵. محاسبه نسبت واریانس توضیح داده شده توسط مؤلفه‌های اصلی

۶. برازش مدل رگرسیون خطی چندمتغیره با استفاده از روش حداقل مربعات

۷. محاسبه ضرایب رگرسیون با استفاده از شبه معکوس مبتنی بر SVD

۸. بررسی معناداری آماری ضرایب مدل

۹. برآورد احتمال وقوع فروش بالا با استفاده از استدلال بیزی

۳. معرفی داده‌ها

داده‌های مورد استفاده در این پروژه از مجموعه داده Advertising انتخاب شده‌اند. این مجموعه داده شامل هزینه‌های تبلیغاتی در سه رسانه مختلف و میزان فروش حاصل از آن‌ها است. متغیرهای مورد بررسی عبارت‌اند از:

- TV: میزان هزینه تبلیغات در تلویزیون

- Radio: میزان هزینه تبلیغات در رادیو

- Newspaper: میزان هزینه تبلیغات در روزنامه

- Sales: میزان فروش

در این پروژه، سه متغیر اول به عنوان متغیرهای مستقل و متغیر Sales به عنوان متغیر وابسته در نظر گرفته می‌شود.

۴. تحلیل اکتشافی داده‌ها

۴.۱ بررسی اولیه داده‌ها (Initial Data Inspection)

۴.۱.۱ بارگذاری داده و مشاهده چند سطر اول

نتایج نشان می‌دهد که داده‌ها شامل متغیرهای زیر هستند:

- TV: هزینه تبلیغات در تلویزیون

- Radio: هزینه تبلیغات در رادیو

- Newspaper: هزینه تبلیغات در روزنامه

- Sales: میزان فروش محصول

همچنین یک ستون با نام Unnamed: 0 در داده‌ها وجود دارد که صرفاً نقش شناسه ردیف را دارد.

۴.۱.۲ بررسی ساختار داده‌ها

نتایج نشان داد که مجموعه داده شامل 200 مشاهده است و تمامی متغیرها از نوع عددی هستند. این موضوع نشان می‌دهد که داده‌ها برای انجام تحلیل‌های آماری و مدل‌سازی مناسب هستند.

۴.۱.۳ بررسی داده‌های گمشده

برای این منظور از تابع `sum.isnull()` استفاده شد تا تعداد مقادیر گمشده در هر ستون مشخص شود.

نتایج نشان داد که در هیچ‌یک از ستون‌های مجموعه داده مقدار گمشده‌ای وجود ندارد. بنابراین نیازی به انجام عملیات پاک‌سازی داده‌ها یا جایگزینی مقادیر گمشده نیست.

۴.۱.۴ حذف ستون شناسه

ستون Unnamed: 0 که در داده‌ها مشاهده شد، تنها یک شناسه برای شماره‌گذاری ردیف‌ها است و در تحلیل آماری و مدل‌سازی نقشی ندارد. به همین دلیل این ستون از مجموعه داده حذف شد تا تحلیل‌ها تنها بر روی متغیرهای اصلی تمرکز داشته باشند.

پس از حذف این ستون، مجموعه داده شامل چهار متغیر اصلی `Sales`، `Newspaper`، `Radio`، `TV` و `Sales` شد.

۴.۲ آمار توصیفی (Descriptive Statistics)

در این مرحله شاخص‌های آماری اصلی برای هر متغیر محاسبه می‌شوند تا دید اولیه‌ای از مرکز داده‌ها، میزان پراکندگی و دامنه تغییرات به دست آید.

این شاخص‌ها شامل موارد زیر هستند:

- میانگین (Mean)
- انحراف معیار (Standard Deviation)
- کمینه (Minimum)
- بیشینه (Maximum)
- چارک‌ها (Quartiles)

۴.۲.۱ محاسبه آمار توصیفی

در این مرحله، شاخص‌های آمار توصیفی برای متغیرهای مجموعه داده محاسبه شدند. برای این منظور از تابع `describe()` در کتابخانه `pandas` استفاده شد که اطلاعاتی مانند میانگین، انحراف معیار، کمینه، بیشینه و چارک‌های داده‌ها را ارائه می‌دهد.

	TV	Radio	Newspaper	Sales
count	200.000000	200.000000	200.000000	200.000000
mean	147.042500	23.264000	30.554000	14.022500
std	85.854236	14.846809	21.778621	5.217457
min	0.700000	0.000000	0.300000	1.600000
25%	74.375000	9.975000	12.750000	10.375000
50%	149.750000	22.900000	25.750000	12.900000
75%	218.825000	36.525000	45.100000	17.400000
max	296.400000	49.600000	114.000000	27.000000

با بررسی جدول آمار توصیفی خروجی متد `describe()`، نکات کلیدی زیر استخراج شد:

- **توزیع هزینه‌ها (TV vs Others):** متغیر TV با میانگین حدود ۱۴۷.۰۴ واحد، بیشترین سهم از هزینه‌های تبلیغاتی را به خود اختصاص داده است. این در حالی است که میانگین هزینه در Radio (۲۳.۲۶) و Newspaper (۳۰.۵۵) به مراتب کمتر است. این موضوع نشان‌دهنده تمرکز اصلی بودجه تبلیغاتی بر رسانه تلویزیون است.
- **پراکندگی داده‌ها (Standard Deviation):** انحراف معیار متغیر TV (۸۵.۸۵) بسیار بالاست که نشان‌دهنده پراکندگی زیاد بودجه در این بخش است (از حداقل ۰.۷ تا حداکثر ۲۹۶.۴). در مقابل، میزان فروش (Sales) انحراف معیار پایینی (۵.۲۱) دارد که نشان می‌دهد داده‌های فروش حول میانگین (۱۴۰.۲) تمرکز نسبتاً خوبی دارند.
- **بررسی چولگی (Skewness) اولیه:** در متغیر Newspaper، میانگین (۳۰.۵۵) از میانه یا همان چارک دوم (۲۵.۷۵) بزرگ‌تر است. این موضوع نشان‌دهنده احتمال وجود چولگی به راست (Right Skew) و وجود مقادیر بسیار بالا (Outliers) در تبلیغات روزنامه است (بیشینه ۱۱۴ در مقابل میانگین ۳۰).
- **وضعیت فروش (Sales):** میانگین فروش ۱۴۰.۲ و میانه آن ۱۲.۹ است که نزدیکی این دو عدد نشان‌دهنده توزیع نسبتاً متقارن در بخش فروش است.

۴.۳ تحلیل بصری با هیستوگرام (Histograms)

حالا برای اینکه تحلیل بالا را به صورت تصویری هم ثابت کنیم، باید هیستوگرام‌ها را رسم کنیم.

با رسم هیستوگرام برای متغیرهای ورودی و خروجی، ویژگی‌های توزیعی داده‌ها به شرح زیر تحلیل شد:

TV و Radio: توزیع هزینه‌ها در این دو رسانه تقریباً **یکنواخت (Uniform)** است. به این معنا که بودجه‌های تبلیغاتی به طور

نسبتاً مساوی در بازه‌های مختلف (کم، متوسط و زیاد) پخش شده‌اند و تمرکز خاصی روی یک بودجه خاص وجود ندارد.


Newspaper: برخلاف دو رسانه قبلی، توزیع تبلیغات در روزنامه دارای **چولگی به راست (Right-Skewed)** است. یعنی در اکثر موارد، هزینه کمی برای روزنامه صرف شده و تنها در موارد معدودی بودجه‌های بسیار سنگین (بالای ۸۰ واحد) تخصیص یافته است.

Sales: توزیع میزان فروش تا حد زیادی به **توزیع نرمال (Normal Distribution)** نزدیک است. بیشترین فراوانی فروش در بازه ۱۰ تا ۱۵ واحد قرار دارد و به سمت طرفین (فروش‌های بسیار کم یا بسیار زیاد) از تعداد فراوانی‌ها کاسته می‌شود.

۴.۴ شناسایی داده‌های پرت با باکس پلات (Boxplots)

هدف از این مرحله این است که ببینیم آیا مقادیر "عجیب" یا "خیلی دور از مرکز" (Outliers) داریم که مدل رگرسیون ما را خراب کنند یا خیر.

Boxplot Analysis of Advertising Dataset



با بررسی نمودارهای جعبه‌ای (Boxplot) برای چهار متغیر موجود، نتایج زیر حاصل شد:

- **عدم وجود داده پرت در اکثر متغیرها:** متغیرهای TV، Radio و Sales فاقد هرگونه داده پرت (Outlier) هستند. این نشان‌دهنده سلامت داده‌ها در این بخش‌هاست و مدل رگرسیون ما از این جهت تحت تأثیر مقادیر غیرعادی قرار نخواهد گرفت.
- **شناسایی داده‌های پرت در Newspaper:** در نمودار مربوط به **روزنامه (Newspaper)**، دو نقطه در سمت راست (بالتر از حد Whiskers) مشاهده می‌شوند. این نقاط نشان می‌دهند که در چند مورد خاص، بودجه‌های تبلیغاتی بسیار سنگینی (بیش از ۱۰۰ واحد) صرف روزنامه شده است که با رفتار کلی داده‌ها متفاوت است.


- تقارن و توزیع:

✓ در TV و Radio، خط میانه (Median) تقریباً در وسط جعبه قرار دارد که نشان‌دهنده توزیع نسبتاً متقارن است.

✓ در Newspaper، میانه به سمت چپ جعبه تمایل دارد که تاییدکننده همان چولگی به راست است که در هیستوگرام دیده بودیم.

۴.۵ تحلیل همبستگی (Correlation Analysis)

حالا که متوجه شدیم داده‌ها تمیز هستند و فقط در روزنامه کمی داده پرت داریم، باید ببینیم کدام یک از این رسانه‌ها رابطه قوی‌تری با فروش (Sales) دارند. این کار را با نقشه حرارتی (Heatmap) انجام می‌دهیم.



با توجه به نقشه حرارتی بدست آمده این نتایج حاصل شد:

- بیشترین همبستگی با Sales مربوط به TV با مقدار ۰.۷۸ است. این مقدار نشان می‌دهد که بین هزینه‌ی تبلیغات تلویزیونی و فروش، رابطه‌ای قوی و مثبت وجود دارد؛ بنابراین TV مؤثرترین متغیر در پیش‌بینی فروش به نظر می‌رسد.

- پس از TV، Radio با همبستگی ۰.۵۸ در رتبه‌ی دوم قرار دارد. این رابطه نیز مثبت و نسبتاً قابل توجه است، اما قدرت آن از TV کمتر است.
 - Newspaper کمترین همبستگی را با Sales دارد و مقدار آن ۰.۲۳ است. این عدد نشان می‌دهد که تبلیغات در روزنامه نسبت به دو رسانه‌ی دیگر، ارتباط ضعیف‌تری با فروش دارد.
 - همچنین بین خود متغیرهای ورودی، TV و Radio کمترین همبستگی را دارند (۰.۰۵)، که بیانگر مستقل بودن نسبی این دو متغیر از یکدیگر است.
- در نتیجه، می‌توان گفت که TV مهم‌ترین عامل تبلیغاتی در افزایش فروش در این دیتاست است و Newspaper کم اثر ترین متغیر نسبت به فروش محسوب می‌شود.

۵. تحلیل ماتریسی و کاهش ابعاد

۵.۱ محاسبه ماتریس کوواریانس هزینه‌های تبلیغات

در این مرحله، ماتریس کوواریانس برای سه متغیر تبلیغاتی TV، Radio و Newspaper محاسبه شد تا میزان پراکندگی هر متغیر و همچنین نوع رابطه خطی بین آن‌ها بررسی شود.

مطابق خروجی، مقدار واریانس متغیر TV برابر با ۷۳۷۰.۹۵ است که از دو متغیر دیگر بسیار بزرگ‌تر است؛ بنابراین هزینه تبلیغات در تلویزیون بیشترین پراکندگی را در داده‌ها دارد. همچنین واریانس Newspaper برابر با ۴۷۴.۳۱ و واریانس Radio برابر با ۲۲۰.۴۳ به‌دست آمد که نشان می‌دهد تغییرات این دو متغیر نسبت به TV کمتر است.

مقادیر خارج از قطر اصلی، کوواریانس بین متغیرها را نشان می‌دهند. همه این مقادیر مثبت هستند؛ بنابراین بین هزینه تبلیغات در رسانه‌های مختلف، رابطه مستقیم وجود دارد. به‌طور خاص، کوواریانس بین Radio و Newspaper برابر با ۱۱۴.۵۰ و بین TV و Newspaper برابر با ۱۰۵.۹۲ است که نسبت به کوواریانس TV و Radio با مقدار ۶۹.۸۶ کمی بزرگ‌تر هستند. در نتیجه می‌توان گفت افزایش هزینه در یک رسانه، معمولاً با افزایش هزینه در رسانه‌های دیگر نیز همراه است، هرچند شدت این رابطه خیلی زیاد نیست.

۵.۲ استخراج مقادیر ویژه و بردارهای ویژه

در این گام از ماتریس کوواریانس مرحله قبل استفاده می‌کنیم و Eigenvalues و Eigenvectors را به‌دست می‌آوریم. این دو، اطلاعات کلیدی در مورد جهت‌ها و میزان پراکندگی داده‌ها ارائه می‌دهند.

۱. مقادیر ویژه (Eigenvalues):

مقادیر ویژه به دست آمده عبارتند از: [۷۳۷۳.۲۹, ۵۱۶.۰۸, ۱۷۶.۳۲].

این اعداد نشان دهنده میزان واریانس (پراکندگی) داده‌ها در راستای هر یک از بردارهای ویژه متناظرشان هستند. مقدار ویژه اول (۷۳۷۳.۲۹) به طور قابل توجهی بزرگ‌تر از دو مقدار دیگر است. این بدان معناست که بیشترین میزان اطلاعات و تغییرات در داده‌ها، در راستای اولین بردار ویژه قرار دارد. مقدار ویژه دوم (۵۱۶.۰۸) دومین میزان پراکندگی را نشان می‌دهد و مقدار سوم (۱۷۶.۳۲) کمترین پراکندگی را در میان این سه مؤلفه دارد.

۲. بردارهای ویژه (Eigenvectors):

بردارهای ویژه، جهت‌های اصلی تغییرات در داده‌ها را مشخص می‌کنند. خروجی به صورت ستون‌های ماتریس بردار ویژه ظاهر شده است:

- بردار ویژه اول (متناظر با مقدار ویژه ۷۳۷۳.۲۹):

$$\begin{bmatrix} 0.9998 \\ 0.0100 \\ 0.0155 \end{bmatrix}$$

این بردار نشان می‌دهد که مؤلفه اصلی تغییرات داده‌ها تقریباً به طور کامل تحت تأثیر متغیر TV (با ضریب ۰.۹۹۹۸) است. بنابراین، بیشترین بخش پراکندگی داده‌ها به دلیل تغییرات در هزینه‌های تبلیغات تلویزیونی است.

- بردار ویژه دوم (متناظر با مقدار ویژه ۵۱۶.۰۸):

$$\begin{bmatrix} 0.0181 \\ -0.3574 \\ -0.9338 \end{bmatrix}$$

این بردار، ترکیبی از متغیرهای Newspaper (با ضریب -۰.۹۳۳۸) و Radio (با ضریب ۰.۳۵۷۴) را نشان می‌دهد. مؤلفه دوم بیانگر تغییری است که عمدتاً تحت تأثیر هزینه‌های تبلیغات در روزنامه و تا حدی رادیو قرار دارد.

- بردار ویژه سوم (متناظر با مقدار ویژه ۱۷۶.۳۲):

$$\begin{bmatrix} 0.0038 \\ -0.9339 \\ 0.3575 \end{bmatrix}$$

این بردار نیز ترکیبی از متغیرهای Radio (با ضریب -۰.۹۳۳۹) و Newspaper (با ضریب ۰.۳۵۷۵) است. حضور این دو متغیر با علامت‌های مخالف در این بردار، نشان دهنده نوعی تضاد یا تقابل بین الگوی هزینه تبلیغات رادیویی و روزنامه‌ای است. در این مؤلفه، متغیر Radio بیشترین تأثیر را دارد.

نتیجه گیری کلی:

تحلیل مقادیر و بردارهای ویژه نشان می دهد که متغیر TV بیشترین سهم را در پراکندگی داده ها دارد. سپس، دو مؤلفه دیگر که ترکیبی از متغیرهای Radio و Newspaper هستند، به ترتیب میزان کمتری از پراکندگی را توضیح می دهند. این یافته ها پایه ای برای کاهش ابعاد و درک بهتر روابط بین متغیرهای ورودی فراهم می کنند.

۵.۳ انجام SVD روی داده های استاندارد شده

در این مرحله چون مقیاس متغیرها متفاوت است، ابتدا داده ها را استاندارد می کنیم تا میانگین هر ستون صفر و انحراف معیار آن یک شود. سپس تجزیه SVD را انجام می دهیم.

مقادیر منفرد به دست آمده برابرند با:

$$[16.56, 14.02, 11.37]$$

بزرگ تر بودن مقدار منفرد اول نشان می دهد که مؤلفه اول بیشترین میزان اطلاعات یا تغییرات داده های استاندارد شده را در خود دارد. مقدار دوم نیز نسبتاً بزرگ است، بنابراین مؤلفه دوم هم بخش قابل توجهی از ساختار داده را توضیح می دهد.

ماتریس VT جهت مؤلفه های اصلی را نشان می دهد. سطر اول:

$$[-0.2079, -0.6914, -0.6919]$$

نشان می دهد که مؤلفه اول بیشتر ترکیبی از متغیرهای Radio و Newspaper است، زیرا ضرایب این دو متغیر نسبت به TV بزرگ تر هستند.

سطر دوم:

$$[-0.9781, 0.1497, 0.1443]$$

نشان می دهد که مؤلفه دوم عمدتاً تحت تأثیر متغیر TV قرار دارد؛ زیرا ضریب مربوط به TV از نظر قدر مطلق بسیار بزرگ تر از دو متغیر دیگر است.

سطر سوم:

$$[0.0038, 0.7068, -0.7074]$$

بیانگر نوعی تقابل بین Radio و Newspaper است؛ زیرا ضرایب این دو تقریباً برابر ولی با علامت مخالف هستند. بنابراین این مؤلفه بیشتر تفاوت بین الگوی هزینه تبلیغات رادیویی و روزنامه‌ای را نشان می‌دهد.

در مجموع، نتایج SVD نشان می‌دهد که پس از استانداردسازی، ساختار داده‌ها تنها وابسته به TV نیست و ترکیب متغیرهای Radio و Newspaper نیز نقش مهمی در مؤلفه‌های اصلی دارد.

۵.۴ محاسبه نسبت واریانس توضیح داده‌شده (Explained Variance Ratio)

در این گام بررسی می‌کنیم که هر کدام از این مؤلفه‌هایی که از طریق SVD به دست آوردیم، چند درصد از کل اطلاعات (واریانس) داده‌های ما را پوشش می‌دهند. این کار به ما کمک می‌کند بفهمیم آیا می‌توانیم ابعاد داده‌ها را کاهش دهیم یا خیر.

در تجزیه SVD، واریانس توضیح داده‌شده توسط هر مؤلفه با مربع مقادیر منفرد (σ) متناسب است. لذا برای محاسبه نسبت واریانس هر مؤلفه از فرمول زیر استفاده گردید:

$$\text{Explained Variance Ratio}_i = \frac{\sigma_i^2}{\sum_{j=1}^3 \sigma_j^2}$$

که در آن σ_i مقدار منفرد مؤلفه i ام است. بر اساس خروجی‌های به دست آمده، نتایج به شرح زیر تحلیل می‌شود:

- مؤلفه اصلی اول (PC1): با اختصاص ۴۵.۷۰٪ از کل واریانس، مهم‌ترین جهت تغییرات داده‌ها را نشان می‌دهد.
- مؤلفه اصلی دوم (PC2): حدود ۳۲.۷۸٪ از اطلاعات را پوشش می‌دهد.
- مؤلفه اصلی سوم (PC3): حدود ۲۱.۵۳٪ از واریانس را شامل می‌شود.

تحلیل مجموع واریانس (Cumulative Variance):

با محاسبه مجموع تجمعی طبق رابطه $\sum_{i=1}^k \text{Ratio}_i$ ، مشاهده می‌شود که دو مؤلفه اول در مجموع ۷۸.۴۷٪ از کل واریانس داده‌ها را توضیح می‌دهند. این مقدار نشان‌دهنده توانایی بالای این دو مؤلفه در بازنمایی ساختار اصلی داده‌هاست. به عبارت دیگر، با حذف مؤلفه سوم و کاهش ابعاد از ۳ به ۲، ما تنها حدود ۲۱.۵ درصد از اطلاعات (که عمدتاً ناشی از تفاوت‌های جزئی بین تبلیغات رادیویی و روزنامه‌ای بود) را از دست می‌دهیم. این تحلیل، اساس فشرده‌سازی داده‌ها و درک اولویت‌بندی متغیرهای تبلیغاتی را فراهم می‌سازد.

۶. مدل سازی رگرسیون خطی

۶.۱ تعریف مدل و آماده سازی ماتریس طراحی

هدف این گام

در این گام قرار نیست هنوز ضرایب مدل را محاسبه کنیم. فقط می خواهیم داده ها را به فرمی تبدیل کنیم که برای حل ماتریسی رگرسیون آماده باشند.

مدل مورد نظر ما این است:

$$Sales = \beta_0 + \beta_1 TV + \beta_2 Radio + \beta_3 Newspaper$$

برای حل ماتریسی، این مدل را به فرم زیر می نویسیم:

$$y = X\beta + \varepsilon$$

که در آن:

- y : بردار خروجی یا همان مقدارهای Sales
- X : ماتریس طراحی شامل ستون ثابت و متغیرهای ورودی
- β : بردار ضرایب مدل
- ε : خطای مدل

ساختار ماتریس طراحی

چون مدل ما عرض از مبدأ دارد، یعنی شامل β_0 است، باید یک ستون شامل عدد ۱ به ابتدای ماتریس ویژگی ها اضافه کنیم.

پس ماتریس طراحی به شکل زیر ساخته می شود:

$$X = \begin{bmatrix} 1 & TV_1 & Radio_1 & Newspaper_1 \\ 1 & TV_2 & Radio_2 & Newspaper_2 \\ 1 & TV_3 & Radio_3 & Newspaper_3 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & TV_n & Radio_n & Newspaper_n \end{bmatrix}$$

و بردار ضرایب برابر است با:

$$\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{bmatrix}$$

بردار پاسخ نیز:

$$y = \begin{bmatrix} Sales_1 \\ Sales_2 \\ Sales_3 \\ \vdots \\ Sales_n \end{bmatrix}$$

نتیجه

در این مرحله، مدل رگرسیون خطی چندگانه برای پیش‌بینی میزان فروش (Sales) بر اساس هزینه‌های تبلیغاتی در سه رسانه تلویزیون، رادیو و روزنامه به صورت زیر تعریف گردید:

$$Sales = \beta_0 + \beta_1 \cdot TV + \beta_2 \cdot Radio + \beta_3 \cdot Newspaper + \epsilon$$

جهت حل این مدل به روش ماتریسی، ماتریس طراحی (X) تشکیل شد. با توجه به وجود پارامتر عرض از مبدأ (β_0)، یک ستون شامل مقدار ثابت 1 به ماتریس ویژگی‌ها اضافه گردید تا مدل به فرم $y = X\beta$ قابل محاسبه باشد. خروجی این گام منجر به ایجاد ماتریس X با ابعاد 200×4 و بردار پاسخ y با ابعاد 200×1 گردید که زیربنای محاسبات در مراحل بعدی است.

۶.۲ محاسبه ضرایب مدل با روش حداقل مربعات و شبه معکوس SVD

در گام قبل، ماتریس طراحی X و بردار پاسخ y را ساختیم. حالا هدف این است که ضرایب مدل رگرسیون خطی را محاسبه کنیم.

مدل ما به صورت زیر است:

$$Sales = \beta_0 + \beta_1 TV + \beta_2 Radio + \beta_3 Newspaper$$

یا به فرم ماتریسی:

$$y = X\beta + \epsilon$$

در این گام باید بردار ضرایب زیر را به دست آوریم:

$$\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{bmatrix}$$

۶.۲.۱ روش اول: محاسبه ضرایب با استفاده از معادله نرمال

در این روش، ضرایب رگرسیون با استفاده از رابطه کلاسیک حداقل مربعات محاسبه می‌شوند:

$$\beta = (X^T X)^{-1} X^T y$$

در این، ضرایب مدل رگرسیون خطی چندگانه به صورت زیر محاسبه شدند:

$$\beta_0 = 2.938889, \beta_1 = 0.045765, \beta_2 = 0.188530, \beta_3 = -0.001037$$

بنابراین معادله مدل به شکل زیر به دست آمد:

$$\widehat{Sales} = 2.938889 + 0.045765(TV) + 0.188530(Radio) - 0.001037(Newspaper)$$

این نتایج نشان می‌دهند که با ثابت بودن سایر متغیرها، افزایش هزینه تبلیغات در TV و Radio با افزایش فروش پیش‌بینی شده همراه است، زیرا ضرایب این دو متغیر مثبت هستند. در مقابل، ضریب Newspaper بسیار کوچک و منفی به دست آمده که بیانگر آن است که اثر این متغیر در حضور سایر رسانه‌ها بسیار ناچیز است.

با این حال، باید توجه داشت که این ضرایب بر اساس **مقیاس اصلی داده‌ها** محاسبه شده‌اند. بنابراین اگرچه ضریب Radio از نظر عددی بزرگ‌تر از ضریب TV است، اما این موضوع به تنهایی برای نتیجه‌گیری درباره مهم‌تر بودن Radio کافی نیست. هر ضریب فقط نشان می‌دهد که با **یک واحد افزایش** در همان متغیر، فروش چه مقدار تغییر می‌کند؛ در نتیجه تفاوت در مقیاس و دامنه متغیرها می‌تواند باعث شود که مقایسه مستقیم ضرایب خام گمراه‌کننده باشد.

۶.۲.۲ روش دوم: محاسبه ضرایب با استفاده از شبه‌معکوس مبتنی بر SVD

در این روش، ابتدا ماتریس X به کمک SVD تجزیه می‌شود:

$$X = U \Sigma V^T$$

سپس شبه‌معکوس آن از رابطه زیر به دست می‌آید:

$$X^+ = V \Sigma^+ U^T$$

و در نهایت ضرایب مدل محاسبه می‌شوند:

$$\beta = X^+ y$$

در این روش نیز ضرایب مدل به صورت زیر محاسبه شدند:

$$\beta_0 = 2.938889, \beta_1 = 0.045765, \beta_2 = 0.188530, \beta_3 = -0.001037$$

در نتیجه، معادله نهایی مدل در این روش نیز به همان صورت زیر به دست آمد:

$$\widehat{Sales} = 2.938889 + 0.045765(TV) + 0.188530(Radio) - 0.001037(Newspaper)$$

با توجه به مقادیر محاسبه شده مشابه روش اول، تفسیر این ضرایب مشابه روش اول است.

۶.۲.۳ مقایسه نهایی نتایج دو روش

نتایج دو روش کاملاً یکسان بودند؛ بنابراین صحت محاسبات و سازگاری دو رویکرد تأیید می شود. هر دو روش نشان دادند که TV و Radio اثر مثبت و Newspaper اثر ناچیزی بر فروش دارد. با این وجود، قضاوت درباره اینکه کدام متغیر مهم تر است، نیازمند بررسی ضرایب استاندارد شده است.

۶.۳ محاسبه خطای استاندارد ضرایب

تا اینجا ضرایب رگرسیون را به دست آوردیم، اما خودِ ضریب به تنهایی کافی نیست.

باید بدانیم هر ضریب با چه میزان عدم قطعیت برآورد شده است. این عدم قطعیت با خطای استاندارد اندازه گیری می شود.

اگر خطای استاندارد یک ضریب کوچک باشد، یعنی مقدار آن با دقت بیشتری برآورد شده است.

اگر بزرگ باشد، یعنی اطمینان ما به آن کمتر است.

در رگرسیون خطی، ماتریس کوواریانس ضرایب از رابطه زیر به دست می آید:

$$\text{Cov}(\hat{\beta}) = \hat{\sigma}^2 (X^T X)^{-1}$$

که در آن:

$$\hat{\sigma}^2 = \frac{RSS}{n - p}$$

• RSS : مجموع مربعات باقیمانده ها

• n : تعداد نمونه ها

• p : تعداد پارامترها با احتساب عرض از مبدأ

سپس خطای استاندارد هر ضریب از جذر درایه های قطری این ماتریس به دست می آید:

$$SE(\hat{\beta}_j) = \sqrt{\text{Var}(\hat{\beta}_j)}$$

نتیجه:

در این مرحله، ابتدا مجموع مربعات باقیمانده‌ها و واریانس خطای مدل محاسبه شد. مقدار مجموع مربعات باقیمانده‌ها برابر است با:

$$RSS = 556.8253$$

همچنین برآورد واریانس خطا برابر با مقدار زیر به دست آمد:

$$\hat{\sigma}^2 = 2.8409$$

این مقدار نشان‌دهنده میزان پراکندگی خطاهای مدل حول مقادیر واقعی فروش است.

سپس با استفاده از ماتریس کوواریانس ضرایب، خطای استاندارد هر ضریب محاسبه شد. نتایج به دست آمده به صورت زیر است:

Coefficient	Estimate	Std_Error
Intercept	2.938889	0.311908
TV	0.045765	0.001395
Radio	0.18853	0.008611
Newspaper	-0.001037	0.005871

بر اساس این نتایج، ضرایب TV و Radio دارای خطای استاندارد نسبتاً کوچکی هستند؛ بنابراین برآورد آن‌ها از دقت مناسبی برخوردار است. در مقابل، مقدار ضریب Newspaper بسیار کوچک‌تر از خطای استاندارد آن است؛ بنابراین انتظار می‌رود این متغیر در آزمون معناداری آماری، اثر قابل توجهی نشان ندهد.

در مجموع، این مرحله نشان داد که ضرایب TV و Radio با اطمینان بیشتری برآورد شده‌اند، در حالی که ضریب Newspaper از نظر آماری مشکوک به عدم معناداری است و باید در گام بعد با آماره t مقدار p -value بررسی شود.

۴.۶ آزمون t برای ضرایب رگرسیون

در این مرحله برای بررسی معناداری هر ضریب، از آزمون t استفاده می‌شود.

فرضیات آزمون برای هر ضریب به صورت زیر است:

$$H_0: \beta_i = 0 \quad H_1: \beta_i \neq 0$$

آماره آزمون نیز از رابطه زیر به دست می آید:

$$t_i = \frac{\hat{\beta}_i}{SE(\hat{\beta}_i)}$$

نتیجه:

نتایج نشان می دهد مقدار آماره t برای عرض از مبدأ برابر با ۹.۴۲ است که نشان دهنده معناداری آن در مدل است. همچنین برای متغیرهای TV و Radio به ترتیب مقادیر ۳۲.۸۱ و ۲۱.۸۹ به دست آمد که بسیار بزرگ هستند و نشان می دهند این دو متغیر اثر معناداری بر فروش دارند. در مقابل، مقدار آماره t برای Newspaper برابر با -۰.۱۸ است که بسیار نزدیک به صفر می باشد. بنابراین شواهد کافی برای معنادار بودن اثر این متغیر وجود ندارد. در نتیجه، آزمون t نشان می دهد که متغیرهای TV و Radio در مدل معنادار هستند، اما Newspaper اثر آماری معناداری ندارد.

۶.۵ محاسبه p -value ضرایب

بعد از محاسبه آماره t ، لازم است مشخص شود که آیا مقدار به دست آمده برای هر ضریب از نظر آماری معنادار است یا خیر. برای این کار از مقدار p -value استفاده می شود.

p -value نشان می دهد اگر فرض صفر درست باشد، یعنی ضریب واقعی یک متغیر برابر صفر باشد، احتمال مشاهده آماره ای به اندازه مقدار فعلی یا شدیدتر از آن چقدر است. هرچه این مقدار کوچک تر باشد، شواهد قوی تری علیه فرض صفر وجود دارد.

در این پروژه سطح معناداری برابر با ۰.۰۵ در نظر گرفته می شود. بنابراین اگر مقدار p -value کمتر از ۰.۰۵ باشد، ضریب مورد نظر معنادار است؛ اما اگر بزرگ تر از ۰.۰۵ باشد، شواهد کافی برای معناداری آن وجود ندارد.

نتیجه:

نتایج نشان می دهد که مقدار p -value برای TV، Intercept و Radio تقریباً برابر با صفر است و از سطح معناداری ۰.۰۵ کمتر می باشد. بنابراین ضرایب این سه بخش از نظر آماری معنادار هستند.

در مقابل، مقدار p -value برای Newspaper برابر با ۰.۸۵۷۳ به دست آمد که بسیار بزرگ تر از ۰.۰۵ است. بنابراین فرض صفر برای این متغیر رد نمی شود و شواهد کافی برای معنادار بودن اثر آن بر فروش وجود ندارد.

در نتیجه، متغیرهای TV و Radio پیش بین های معنادار فروش هستند، اما متغیر Newspaper در مدل نقش معناداری ندارد.

۷. استدلال بیزی

۷.۱ تعریف فروش بالا بر اساس میانه

در این بخش، ابتدا میانه فروش محاسبه می‌شود. سپس هر نمونه‌ای که مقدار فروش آن بیشتر از میانه باشد، به‌عنوان «فروش بالا» در نظر گرفته می‌شود.

در این مرحله، ابتدا میانه متغیر فروش محاسبه شد که مقدار آن برابر با ۱۲.۹ به‌دست آمد. طبق تعریف صورت مسئله، فروش‌هایی که مقدار آن‌ها بیشتر از میانه فروش باشد، به‌عنوان **فروش بالا** در نظر گرفته شدند.

بر اساس این معیار، از میان ۲۰۰ نمونه موجود در داده‌ها، تعداد ۹۸ نمونه دارای فروش بالاتر از میانه بودند. بنابراین تعداد موفقیت‌ها در مدل بیزی برابر با ۹۸ و تعداد کل مشاهدات برابر با ۲۰۰ است.

نسبت مشاهده‌شده فروش‌های بالا نیز برابر است با:

$$\frac{98}{200} = 0.49$$

یعنی حدود ۴۹٪ از نمونه‌ها در دسته فروش بالا قرار گرفته‌اند.

۷.۲ به‌روزرسانی توزیع Beta

طبق صورت مسئله، توزیع پیشین برابر است با:

$$Beta(1,1)$$

در مدل Beta-Binomial، اگر تعداد موفقیت‌ها برابر با x و تعداد شکست‌ها برابر با $n - x$ باشد، پارامترهای پسین به شکل زیر به‌روزرسانی می‌شوند:

$$\alpha_{post} = \alpha_{prior} + x$$

$$\beta_{post} = \beta_{prior} + n - x$$

در اینجا داریم:

$$x = 98$$

$$n = 200$$

پس:

$$\alpha_{post} = 1 + 98 = 99$$

$$\beta_{post} = 1 + 102 = 103$$

بنابراین توزیع پسین برابر است با:

$$Beta(99,103)$$

پس از به‌روزرسانی دانش اولیه (توزیع پیشین) با داده‌های واقعی فروش، میانگین پسین برای احتمال رخ دادن فروش بالا برابر با ۰.۴۹۰۱ برآورد شد.

این نتیجه نشان می‌دهد که بر اساس شواهد موجود در داده‌ها و با در نظر گرفتن پیشین یکنواخت، احتمال اینکه یک مشاهده جدید دارای «فروش بالا» (بیشتر از میانه) باشد، حدود ۴۹ درصد است. این برآورد بسیار نزدیک به نسبت مشاهده شده در داده‌ها (۰.۴۹) است، اما به دلیل استفاده از رویکرد بیزی، اثر توزیع پیشین نیز در آن لحاظ شده است.

۸. جمع‌بندی نهایی

این پروژه با هدف تحلیل داده‌های تبلیغاتی و بررسی رابطه بین هزینه‌های تبلیغات و میزان فروش آغاز شد. داده‌های مسئله شامل چند متغیر عددی از جمله میزان تبلیغات در رسانه‌های مختلف و مقدار فروش بود. روند کلی پروژه به‌گونه‌ای طراحی شده بود که ابتدا داده‌ها شناخته شوند، سپس ساختار آن‌ها بررسی شود، در ادامه روابط میان متغیرها به‌صورت کمی مدل‌سازی شود و در نهایت نتایج از دیدگاه آماری و احتمالاتی تفسیر شوند.

شروع پروژه: شناخت داده‌ها با EDA

نخستین گام پروژه، تحلیل اکتشافی داده‌ها (EDA) بود. در این مرحله، ویژگی‌های کلی داده‌ها بررسی شد؛ از جمله نوع متغیرها، ابعاد دیتاست، توزیع مقادیر، وضعیت پراکندگی داده‌ها و رابطه اولیه بین متغیرهای ورودی و خروجی.

اهمیت این مرحله در آن بود که قبل از هر نوع مدل‌سازی، تصویری روشن از ماهیت داده‌ها به دست آید. با EDA می‌توان فهمید که:

- داده‌ها چه ساختاری دارند،

- آیا الگو یا روند مشخصی در آن‌ها دیده می‌شود،
 - آیا متغیرها رفتارهای مشابه یا همبستگی دارند،
 - و آیا داده‌ها برای مدل‌سازی خطی مناسب هستند یا نه.
- در واقع، EDA پایه‌ای برای تصمیم‌گیری در مراحل بعدی بود و کمک کرد تحلیل فقط مبتنی بر فرمول نباشد، بلکه از خود داده شروع شود.

کاهش ابعاد: ساده‌سازی و درک ساختار داده

در ادامه، بخش **کاهش ابعاد** انجام شد. هدف از این مرحله، خلاصه‌سازی اطلاعات موجود در داده‌ها و بررسی این موضوع بود که آیا می‌توان بخش زیادی از تغییرات داده را با تعداد کمتری مؤلفه توضیح داد یا نه.

کاهش ابعاد از دو جهت اهمیت داشت:

۱. درک بهتر ساختار داده‌ها

این مرحله نشان می‌دهد که آیا متغیرها اطلاعات مستقل و متمایزی دارند یا بخشی از اطلاعات آن‌ها هم‌پوشانی دارد.

۲. آماده‌سازی برای تحلیل‌های بعدی

وقتی داده‌ها در فضای کم‌بعدتر بررسی می‌شوند، تفسیر الگوها آسان‌تر می‌شود و می‌توان روابط پنهان بین متغیرها را بهتر تشخیص داد.

بنابراین، کاهش ابعاد در این پروژه فقط یک تکنیک محاسباتی نبود، بلکه ابزاری برای فهم بهتر رفتار داده‌ها و کاهش پیچیدگی مسئله بود.

مدل‌سازی: برقراری رابطه بین تبلیغات و فروش

پس از شناخت داده‌ها، پروژه وارد مرحله مدل‌سازی شد. در این بخش، رابطه بین متغیرهای تبلیغاتی و فروش با استفاده از **رگرسیون خطی چندمتغیره** مدل شد.

برای این کار، ماتریس طراحی X و بردار پاسخ y تشکیل شد و ضرایب مدل به دو روش محاسبه شدند:

$$\beta = (X^T X)^{-1} X^T y$$

$$\beta = X^+ y$$

یکسان بودن نتایج این دو روش نشان داد که محاسبات به درستی انجام شده‌اند و مدل از نظر عددی پایدار است. ضرایب به دست آمده نشان دادند که متغیرهای TV و Radio اثر مثبت بر فروش دارند، در حالی که اثر Newspaper بسیار ناچیز است.

اعتبارسنجی آماری: آیا این اثرها واقعی‌اند؟

در گام بعد، پروژه از سطح «برآورد ضرایب» فراتر رفت و وارد فاز **تفسیر آماری** شد. با استفاده از خطای استاندارد، آماره t و p -value، معناداری ضرایب بررسی شد.

نتایج نشان داد که:

- اثر تبلیغات در **تلویزیون و رادیو** از نظر آماری بسیار معنادار است؛
 - اما اثر **روزنامه** معنادار نیست.
- این بخش یکی از مهم‌ترین نتایج پروژه بود، چون نشان داد که صرفاً داشتن یک ضریب در مدل کافی نیست و باید بررسی شود که آن ضریب واقعاً قابل استناد هست یا نه. از این جهت، پروژه فقط یک مدل عددی تولید نکرد، بلکه کیفیت و اعتبار نتایج را هم سنجید.

نگاه احتمالاتی: استدلال بیزی

در بخش پایانی، پروژه با رویکرد **بیزی** تکمیل شد. در این مرحله، فروش‌های بالاتر از میانه به عنوان «فروش بالا» تعریف شدند و احتمال این رویداد با استفاده از توزیع پیشین و داده‌های مشاهده شده به روزرسانی شد.

نتیجه این تحلیل، یک توزیع پسین برای احتمال فروش بالا بود که میانگین آن حدود 0.49 به دست آمد.

اهمیت این مرحله در آن بود که پروژه فقط به تحلیل کلاسیک محدود نماند، بلکه از زاویه احتمالاتی نیز به داده نگاه کرد. این رویکرد کمک کرد عدم قطعیت موجود در داده‌ها به شکلی روشن‌تر مدل شود.

نتیجه نهایی پروژه

در مجموع، این پروژه از یک تحلیل سطحی روی داده‌ها شروع نشد، بلکه یک مسیر کامل و منطقی را طی کرد:

- ابتدا داده‌ها با **EDA** شناخته شدند؛
- سپس با **کاهش ابعاد** ساختار آن‌ها ساده‌تر و قابل فهم‌تر شد؛
- بعد با **رگرسیون خطی** رابطه بین تبلیغات و فروش کمی‌سازی شد؛
- با **آزمون‌های آماری** مشخص شد کدام روابط واقعاً معنادارند؛
- و در نهایت با **استدلال بیزی** مسئله از منظر احتمال و عدم قطعیت نیز بررسی شد.

مهم‌ترین نتیجه قابل توجه پروژه این بود که همه رسانه‌های تبلیغاتی اثر یکسانی بر فروش ندارند. در این داده‌ها، تبلیغات تلویزیونی و رادیویی نقش مؤثر و معناداری در افزایش فروش داشتند، اما تبلیغات روزنامه‌ای نتوانست اثر معناداری نشان دهد. این نتیجه از نظر تحلیلی و کاربردی ارزشمند است، چون می‌تواند در تصمیم‌گیری برای تخصیص بودجه تبلیغاتی مورد استفاده قرار گیرد.